言語モデルにおける長距離依存関係の内部操作

LLM勉強会 3/17

木村一馬 (バルセロナ自治大学) w/ 大関洋平, 菅原朔

目的

- 長距離依存関係を構築する際の言語モデルの内部表現
- 統語的な依存関係構築はヒューリスティックか言語理論で想定される原理的操作か
- モデルサイズごとに操作の内実は同じか

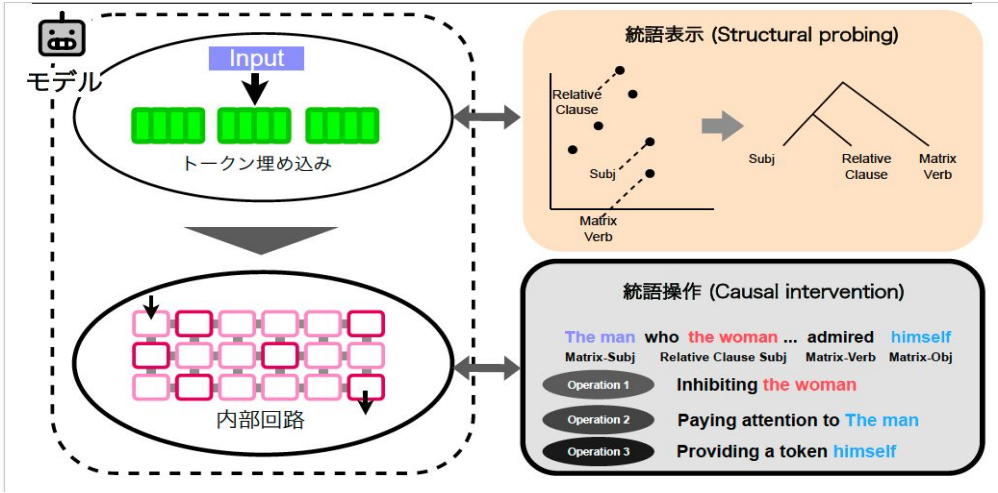

表示に対する操作
（computations over representations）

長距離依存関係

(1) a. **No** students who **some** teachers scolded submitted **any** notebooks.

b. *__Some__ students who **no** teachers scolded submitted **any** notebooks.

構造的に適切な位置(主節主語位置) にある語との依存関係(階層構造・統語的)

言語モデルはどのような方法で依存関係を構築するのか

操作としての内部表現

supervisionなしの手法

- 形式的 (言語学的) タスクの内部表現 (Wang+ (2022))
- 活性パターンの構文間のオーバーラップ(Hanna+ (2025))

supervision ありの手法

- CausalGym : 二値的な特性 (gender, negation)は一次元情報として格納される可能性 (Linear Representation Hypothesis, Arora+(2024), Bograev + (2025))

→事前学習済みモデルで, 依存関係構築に必要な操作の**内容**や**性質**(e.g., どのような情報に依存するのか) は明らかになっていない

本研究の目的:
操作内容が特定可能な手法で長距離依存関係の内部表現を分析

Activation Patching + 注意パターン

- 寄与度の高いヘッド・パスを特定(図A.)
- それらの注意パターンを特定(図B.)

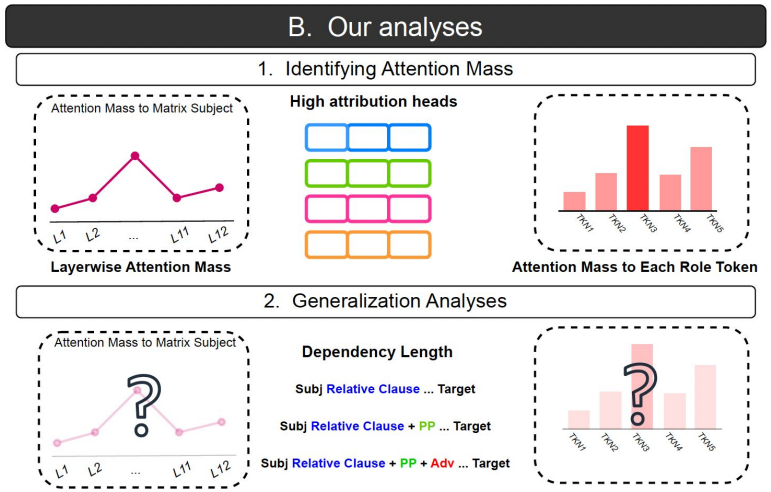

手法

Transformer Lens: 各ヘッドをパッチした時の回復率(corrupted入力がどれだけclean入力の出力に近づくか)を算出

Restoration Score

$$R_\ell = \frac{M^{(\ell)}_{\text{patched}} - M_{\text{corr}}}{M_{\text{clean}} - M_{\text{corr}} + \varepsilon}.$$

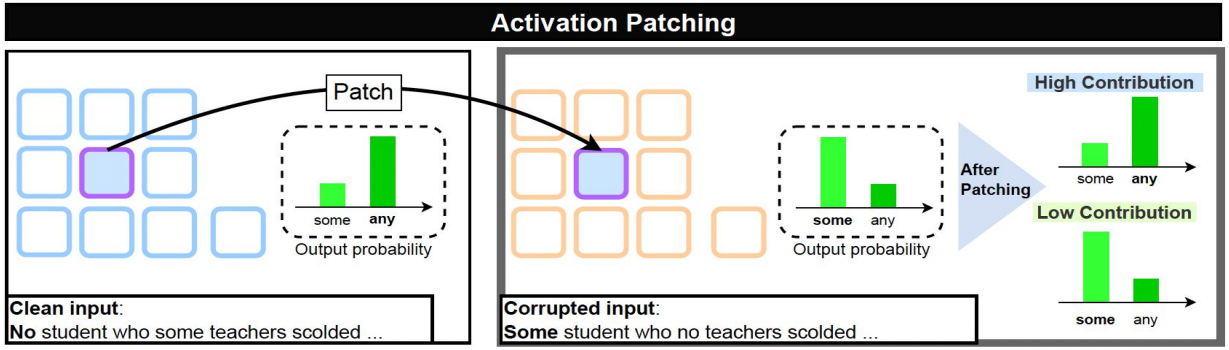

注意パターン分析

注意質量:

ターゲットトークン（主節目的語）位置での各トークンに対する注意重みを集計

$$mass(role) = \sum_{j \in role} \alpha_{target,j}$$

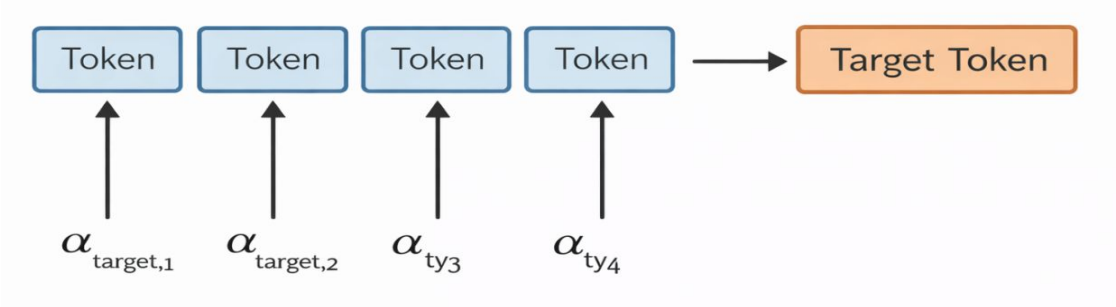

データセット

- 4つの長距離依存関係(NPI, 再帰代名詞束縛, wh-疑問文, 分裂文), **それぞれ300件**
- 特定の位置で依存関係を構築する(主節主語と主節目的語)
- corrupted入力は, 構造的に不適格な位置(関係節内) に依存関係を認可する要素が含まれている

	NPI
Clean	**No** student who some teachers scolded [any] notebook.
Corrupted	**Some** student who some teachers scolded [any] notebook.
	Reflexive
Clean	**The man** who the woman predominantly dislikes admired [himself] yesterday.
Corrupted	**The woman** who the woman predominantly dislikes admired [himself] yesterday.
	Wh
Clean	**Which man** did the woman who wrote the paper [visited] yesterday ?
Corrupted	**Which paper** did the woman who praised the man [visited] yesterday ?
	Cleft
Clean	It is **the man** that the woman who wrote the paper [visited] yesterday.
Corrupted	It is **the paper** that the woman who praised the man [visited] yesterday.

データセット

- 構成素ごとにRoleトークンを付与
- 主節主語 = role_key, 主節目的語 = role_target

	$role_{key}$	$role_{rel}$	$role_{rel-subj}$	$role_{rel-verb}$	$role_{adj}$	$role_{main-verb}$	$role_{target}$
NPI	[No NP]	who	[some NP]	[verb]	[adverb]	[verb]	[any]
Reflexive	[The NP_m]	who	[the NP_f]	[verb]	[adverb]	[verb]	[himself]

	$role_{key}$	$role_{pro}$	$role_{subj}$	$role_{rel}$	$role_{rel-subj}$	$role_{rel-verb}$	$role_{target}$
Wh-depedendency	[Wh NP_a]	did	[the NP_i]	which	[verb]	[adv]	[verb]
Cleft	[It was the NP_a]	who	[the NP_i]	[which]	[verb]	[adv]	[verb]

手法

1. 寄与度の高い上位10ヘッドを抽出
2. 上位10ヘッドの各Roleトークン(主節主語＋関係節主語) に対する注意パターン(注意質量)
3. パッチ前とパッチ後で比較
4. 同様の分析を依存関係の線形距離を変えて行う(付加要素の差し込み, 介在要素2つ/4つの場合)

モデル: GPT-2-Small/Medium/Large

Dependency	Example (linear conditions)
NPI	**No** student who some teachers scolded {*carefully / carefully, in the lab*} [any] notebook.
Reflexive	**The man** who the woman predominantly dislikes {*in the lab / in the lab, two days ago*} admired [himself] yesterday.
Wh	**Which man** did the woman who wrote the paper {*at the conference / at the conference, last year*} [visited] yesterday?
Cleft	It is **the man** that the woman who wrote the paper {*two days ago / two days ago, in the building*} [visited] yesterday.

結果 (GPT-2-Small)

- 全ての依存関係に対して類似した注意パターン(青: パッチ前の注意質量 オレンジ: パッチ後の注意質量)
- 主節主語(role_key)に直接注意が集中する

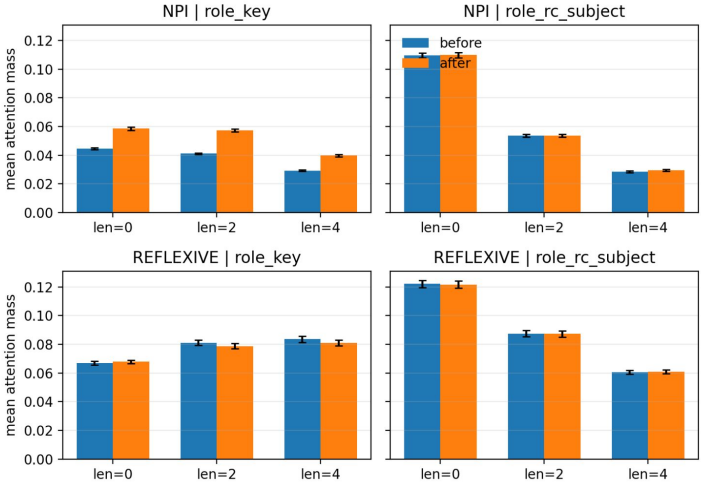

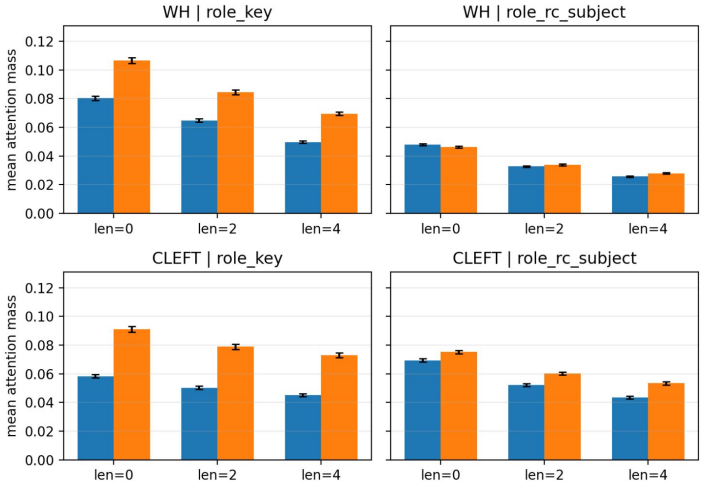

結果 (GPT-2-Large)

- 注意パターンが分化(青: パッチ前の注意質量, オレンジ: パッチ後の注意質量)
- NPI・再帰代名詞: 関係節内の主語(role_rc_subject) に注意が集中
- wh-疑問文・分裂文: 注意はどちらのroleトークンにも集中しない

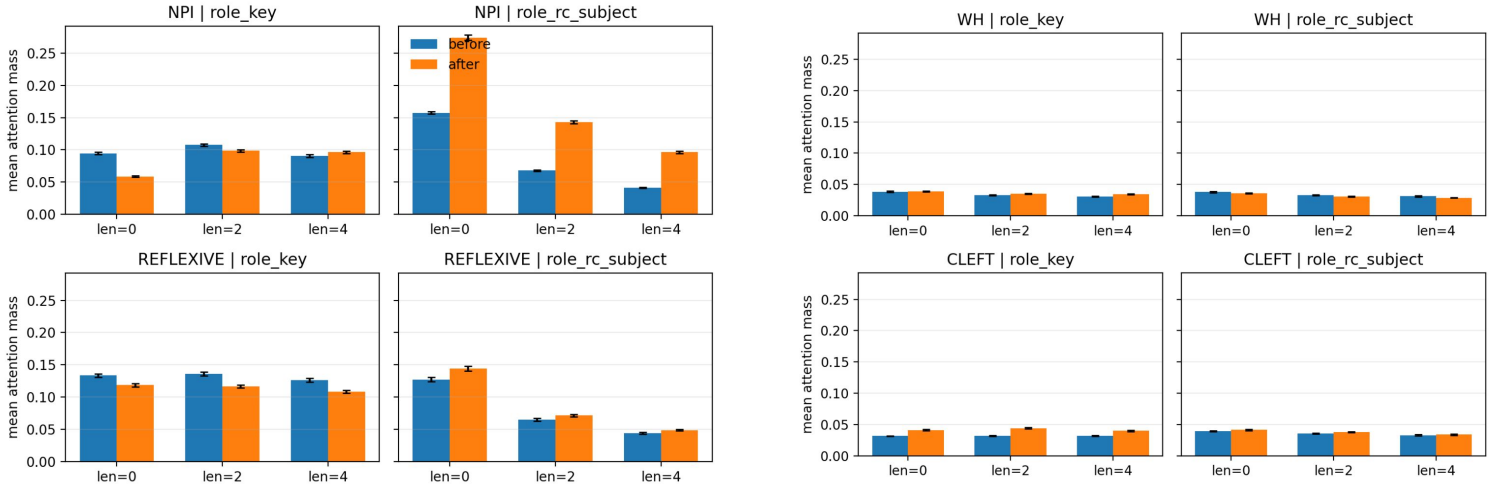

結果（線形距離コントロール ）

- 依存関係を結ぶ要素同士の距離が伸びても層ごとの注意質量の分布は変わらない

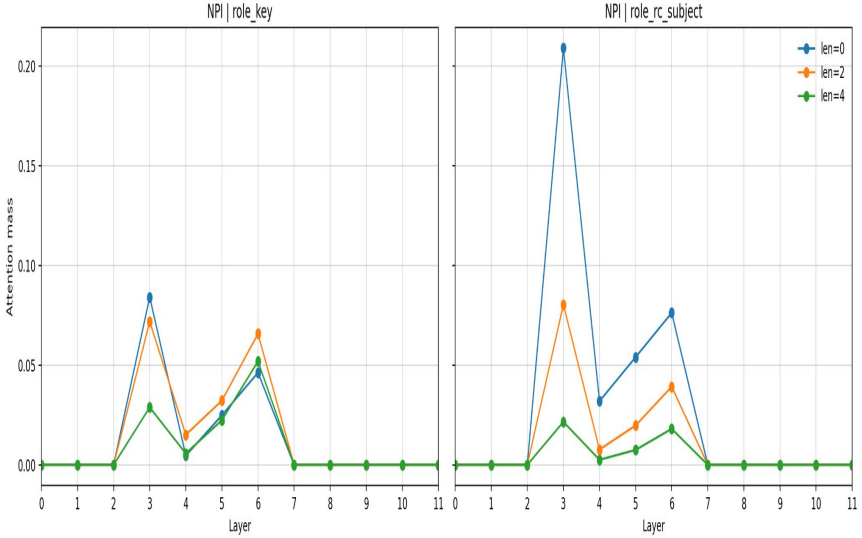

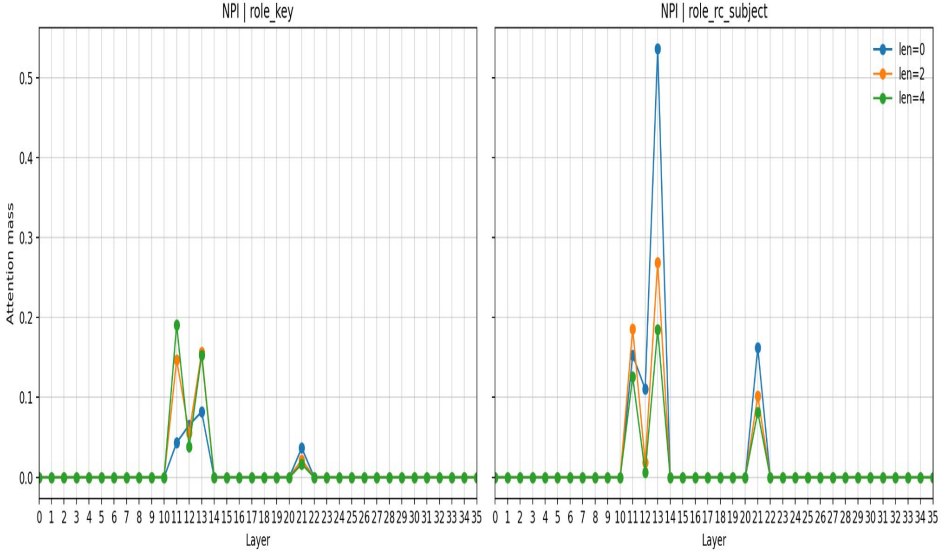

考察

- 小さいモデルサイズでは, 注意パターンが依存関係間で共通している

  →**一般化された操作** (e.g., filler-gap 依存関係構築) or **粗いヒューリスティック** (e.g., 先頭の名詞句に注意を向ける)

- モデルサイズが大きくなると注意パターンが分化

  → **統語移動あり/なし依存関係を識別** or **関与する語彙特性が影響**?

  NPI・再帰代名詞: 構造的に不適格なトークンに注意を向けることで間接的に構造を捉えている?

  wh-疑問文・分裂文: 注意機構以外のコンポーネントで処理されている可能性or 注意機構でも分散的に表現?

- 依存関係の線形距離には頑健

  → **ある程度構造依存**

追加の実験設計（進行中）

操作に関する仮説の検証 (**Counterfactual Intervention**, Nikankin + (2024))

1. GPT-2-Smallでの注意機構：線形ヒューリスティックかどうか（主語名詞句の構成素に対して適用されるかどうか ）

   e.g., 文頭・文中に名詞句を含む付加要素を挿入した入力文

   In the school the boy enrolls the man who the woman dislikes predominantly admires [himself].

2. GPT-2-Largeの構造依存性：

   e.g., 構造・階層性を崩した入力文

   The man in the room that the girl likes admires **himself**.

   The girl in the room that **the man** likes admires **himself**.

追加の実験設計（検討すべき事項）

Top-kヘッドの抽出・統計的評価

- 抽出するヘッドの数(今回の実験はk = 10で抽出)
- 抽出したヘッドを回路とみなせるかどうか
- head ablationを行うかどうか
- パッチ前後の注意質量を統計的にどう評価するか

今後の方針

- 注意機構以外のコンポーネント(MLP, 残差結合変換) およびそれらのフロー

  → Activation Patchingで分析するのは非現実的, Attribution Patchingのような勾配情報による近似的分析

- 統語的**内部操作**を評価できるベンチマークを構築

  → CausalGymのような言語の形式的情報の因果を特定するのではなく

  言語情報の内部操作（メカニズム）を特定できるようなベンチマーク